

# BÁO CÁO TUẦN 4

## THI CÔNG TẦNG 1 — RANDOM FOREST / SVM

### 1. Cài đặt và kiểm thử `extract_features()`

Hàm `extract_features()` được cài đặt theo đúng đặc tả Tuần 3 (16 đặc trưng, thứ tự cột cố định index 0-15). Sau khi áp dụng lên toàn bộ `train.csv`, kết quả thống kê trung bình theo nhãn được đối chiếu lại với số liệu EDA đã có ở báo cáo Tuần 2 để xác nhận công thức tính đúng.

#### 1.1. Đối chiếu kết quả với EDA Tuần 2

| Đặc trưng         | Nhãn 0 (Tuần 2) | Nhãn 1 (Tuần 2) | Nhãn 0 (thực tế) | Nhãn 1 (thực tế) |
|-------------------|-----------------|-----------------|------------------|------------------|
| length            | 39,89           | 118,74          | 39,89            | 118,74           |
| uppercase_ratio   | 0,2372          | 0,0039          | 0,2372           | 0,0039           |
| n_whitespace      | 6,54            | 43,99           | 6,54             | 43,99            |
| n_digit           | 1,71            | 18,32           | 1,71             | 18,32            |
| n_quote           | 0,6615          | 1,1284          | 0,6615           | 1,1284           |
| n_equal           | 0,2089          | 1,2057          | 0,2089           | 1,2057           |
| n_comma           | 0,3354          | 1,8087          | 0,3354           | 1,8087           |
| n_paren           | 0,58            | 7,53            | 0,578            | 7,529            |
| n_percent         | 0,0300          | 0,1968          | 0,0300           | 0,1968           |
| n_comment_markers | 0,00064         | 0,5256          | 0,00064          | 0,5256           |

Kết quả khớp gần như tuyệt đối, chênh lệch chỉ ở phần thập phân thứ 3-4 do làm tròn khi viết báo cáo Tuần 2 — xác nhận `extract_features()` cài đặt đúng, không có sai sót ảnh hưởng đến các bước tiếp theo.

#### 1.2. Danh sách từ khóa cho `keyword_repeat_count`

8 từ khóa được chốt dựa trên kiểm tra tần suất thực tế trên `train.csv` (xem `docs/Week03/Cap_nhat_keyword_repeat_count.md`): UNION, OR, AND, CONCAT, SLEEP, WAITFOR, INFORMATION\_SCHEMA, BENCHMARK. Loại khỏi danh sách: DROP, EXEC, SELECT, EXECUTE (tín hiệu yếu hoặc không xuất hiện), và đặc biệt INSERT/UPDATE/DELETE (xuất hiện nhiều hơn ở câu hợp lệ — chiều tác động ngược với giả định).

#### 1.3. Artifact tiền xử lý — ngưỡng clip percentile 99

Tính trên `train.csv`, riêng cho từng cột trong 12 cột liên tục:

| Đặc trưng            | Ngưỡng P99 |
|----------------------|------------|
| length               | 377,0      |
| uppercase_ratio      | 0,6364     |
| n_whitespace         | 171,0      |
| n_digit              | 55,0       |
| n_quote              | 6,0        |
| n_equal              | 3,0        |
| n_comma              | 8,0        |
| n_paren              | 36,0       |
| n_percent            | 2,0        |
| n_comment_markers    | 1,0        |
| keyword_repeat_count | 3,0        |
| n_semicolon          | 1,0        |

Đáng chú ý: ngưỡng length=377 trùng khớp với percentile 99 đã tính độc lập ở Pipeline 2 (Tuần 3) — một phép kiểm tra chéo xác nhận cả hai lần tính đều đúng. StandardScaler được fit sau khi clip, chỉ trên train.csv. Ma trận đặc trưng cuối cùng: train (24.724, 16), test (6.181, 16), lưu tại artifacts/clip\_thresholds.json, artifacts/tier1\_scaler.pkl, artifacts/feature\_order.json.

## 2. Kết quả Cross-Validation (k=5) trên train.csv

### 2.1. Random Forest

| Metric    | Mean   | Std    | Từng fold                                  |
|-----------|--------|--------|--------------------------------------------|
| Precision | 0,9986 | 0,0007 | 0,9978 / 0,9994 / 0,9989 / 0,9978 / 0,9989 |
| Recall    | 0,9959 | 0,0010 | 0,9962 / 0,9967 / 0,9967 / 0,9962 / 0,9940 |
| F1-score  | 0,9972 | 0,0006 | 0,9970 / 0,9981 / 0,9978 / 0,9970 / 0,9964 |

Thời gian chạy cross-validation: 8,2 giây. Thời gian fit cuối trên toàn bộ train: 1,5 giây.

### 2.2. SVM

| Metric    | Mean   | Std    | Từng fold                                  |
|-----------|--------|--------|--------------------------------------------|
| Precision | 0,9989 | 0,0012 | 1,0000 / 1,0000 / 0,9967 / 0,9989 / 0,9989 |
| Recall    | 0,9912 | 0,0019 | 0,9929 / 0,9918 / 0,9885 / 0,9934 / 0,9896 |
| F1-score  | 0,9950 | 0,0015 | 0,9964 / 0,9959 / 0,9926 / 0,9961 / 0,9942 |

Thời gian chạy cross-validation: 39,8 giây (gấp ~5 lần Random Forest). Thời gian fit cuối trên toàn bộ train: 12,3 giây.

### 2.3. Kiểm tra loại trừ rò rỉ do trùng lặp dữ liệu

Kết quả cross-validation ở mức rất cao ( $F1 > 0,995$  cho cả hai mô hình) cần được xác minh không phải do rò rỉ dữ liệu. Kiểm tra số lượng câu truy vấn trùng lặp gần đúng trong train.csv: không có câu nào xuất hiện từ 2 lần trở lên (0 dòng). Kết hợp với việc 12 dòng trùng lặp tuyệt đối đã bị loại từ Tuần 2, có thể loại trừ khả năng mô hình "nhớ" dữ liệu lặp thay vì học tổng quát. Kết quả cross-validation cao được xác nhận là phản ánh đúng mức độ phân tách mạnh của bộ 16 đặc trưng đã thiết kế, không phải lỗi phương pháp luận.

### 2.4. Giới hạn phương pháp luận cần ghi nhận

clip\_thresholds và tier1\_scaler được fit trên toàn bộ train.csv trước khi chia cross-validation, nghĩa là ngưỡng percentile 99 có "nhìn thấy" một phần dữ liệu của chính fold đang được validate ở mỗi vòng CV — về lý thuyết đây là rò rỉ nhẹ. Với Random Forest, ảnh hưởng gần như không đáng kể vì clip và StandardScaler đều là phép biến đổi đơn điệu, không đổi thứ tự giá trị mà cây quyết định dựa vào để split. Với SVM (nhạy hơn với thang đo tuyệt đối), ảnh hưởng có thể lớn hơn dù chưa định lượng cụ thể — cần nêu rõ đây là giới hạn phương pháp luận khi trình bày kết quả, không phải sai sót nhưng cần được ghi nhận trung thực.

## 3. Kết quả đánh giá trên test.csv

| Mô hình       | Precision | Recall | F1-score | TN   | FP | FN | TP   |
|---------------|-----------|--------|----------|------|----|----|------|
| Random Forest | 0,9978    | 0,9938 | 0,9958   | 3900 | 5  | 14 | 2262 |
| SVM           | 0,9973    | 0,9903 | 0,9938   | 3899 | 6  | 22 | 2254 |

### 3.1. So sánh với cross-validation — kiểm tra overfit

| Mô hình       | F1 cross-validation | F1 trên test | Chênh lệch |
|---------------|---------------------|--------------|------------|
| Random Forest | 0,9972              | 0,9958       | -0,0014    |
| SVM           | 0,9950              | 0,9938       | -0,0012    |

Chênh lệch giữa cross-validation và test rất nhỏ (dưới 0,15 điểm phần trăm) cho cả hai mô hình — không có dấu hiệu overfit, mô hình tổng quát tốt sang dữ liệu chưa từng thấy.

### 3.2. Nhận định Confusion Matrix

False Negative (câu SQLi bị bỏ sót — loại lỗi nguy hiểm nhất cho bài toán bảo mật) của Random Forest thấp hơn SVM: 14 so với 22. False Positive (báo động giả) tương đương giữa hai mô hình (5 so với 6). Về mặt ứng dụng thực tế cho hệ thống middleware chặn truy vấn, Random Forest có lợi thế rõ ràng hơn ở khía cạnh không bỏ lọt tấn công.

## 4. Feature Importance và Ma trận tương quan — Quyết định bộ đặc trưng

### 4.1. Feature importance đầy đủ (Random Forest)

| Hạng | Đặc trưng            | Importance |
|------|----------------------|------------|
| 1    | n_digit              | 0,2374     |
| 2    | keyword_repeat_count | 0,1703     |
| 3    | uppercase_ratio      | 0,1329     |
| 4    | n_equal              | 0,1016     |
| 5    | n_whitespace         | 0,1005     |
| 6    | n_comment_markers    | 0,0830     |
| 7    | n_paren              | 0,0734     |
| 8    | length               | 0,0370     |
| 9    | has_select_from      | 0,0158     |
| 10   | n_comma              | 0,0142     |
| 11   | n_quote              | 0,0141     |
| 12   | has_union            | 0,0097     |
| 13   | has_or               | 0,0060     |
| 14   | n_semicolon          | 0,0021     |
| 15   | n_percent            | 0,0018     |
| 16   | has_drop             | 0,0001     |

### 4.2. Phân tích n\_semicolon, has\_drop, keyword\_repeat\_count

**has\_drop — importance 0,0001 (thấp nhất):** gần như bằng 0, không có tương quan đáng kể với cột nào (keyword\_repeat\_count <-> has\_drop: -0,024). Bằng chứng rõ ràng cho thấy đặc trưng này gần như không đóng góp, khớp với nhận định từ Tuần 2 về tần suất DROP quá thấp.

**n\_semicolon — importance 0,0021 (thứ 14/16):** rất thấp nhưng không nằm trong bất kỳ cặp tương quan >0,5 nào — không dư thừa, chỉ đơn giản là yếu, khớp với phát hiện "chiều tác động ngược" đã ghi nhận từ Tuần 2.

**keyword\_repeat\_count — importance 0,1703 (thứ 2/16):** ngược với nghi ngờ ban đầu về khả năng trùng lặp với has\_union/has\_or/has\_select\_from, đây là đặc trưng mạnh thứ nhì trong toàn bộ 16 đặc trưng. Tương quan với các cột binary liên quan chỉ ở mức trung bình (has\_or: 0,521; has\_union: 0,234; has\_select\_from: 0,046) — không đủ cao để coi là trùng lặp thật sự.

### 4.3. Ma trận tương quan — các cặp đáng chú ý ( $|r| > 0,5$ )

| Cặp đặc trưng                         | Hệ số tương quan |
|---------------------------------------|------------------|
| n_whitespace <-> n_paren              | 0,979            |
| length <-> n_whitespace               | 0,957            |
| length <-> n_paren                    | 0,906            |
| n_whitespace <-> n_digit              | 0,795            |
| n_digit <-> n_paren                   | 0,777            |
| length <-> n_digit                    | 0,766            |
| uppercase_ratio <-> has_select_from   | 0,642            |
| n_equal <-> keyword_repeat_count      | 0,624            |
| n_whitespace <-> keyword_repeat_count | 0,613            |
| length <-> n_equal                    | 0,673            |
| n_whitespace <-> n_equal              | 0,668            |
| n_digit <-> keyword_repeat_count      | 0,591            |
| length <-> keyword_repeat_count       | 0,594            |
| n_digit <-> n_equal                   | 0,572            |
| n_equal <-> n_paren                   | 0,570            |
| n_paren <-> keyword_repeat_count      | 0,546            |
| keyword_repeat_count <-> has_or       | 0,521            |

### 4.4. Phát hiện thêm — length dư thừa với n\_whitespace/n\_paren

length (importance chỉ 0,0370) có tương quan rất cao với n\_whitespace (0,957) và n\_paren (0,906) — hai cột này có importance cao hơn nhiều (0,1005 và 0,0734). Đây là bằng chứng cho thấy length phần lớn là thông tin dư thừa: Random Forest nắm được độ dài câu truy vấn gián tiếp qua n\_whitespace/n\_paren hiệu quả hơn dùng trực tiếp length. Phát hiện này nằm ngoài phạm vi cam kết ban đầu của Tuần 3 (chỉ giới hạn ở n\_semicolon/has\_drop/keyword\_repeat\_count), được ghi nhận lại để tham khảo cho các lần điều chỉnh mô hình sau này (Tuần 7 hoặc các đề án mở rộng), không xử lý ở Tuần 4.

### 4.5. Quyết định cuối về bộ đặc trưng

**Giữ nguyên toàn bộ 16 đặc trưng, không loại bỏ ở Tuần 4.** Lý do: mặc dù has\_drop và n\_semicolon có importance rất thấp, chúng không gây hại — Random Forest gần như bỏ qua các đặc

trung có importance gần 0 khi chọn điểm chia (split), nên việc giữ lại không làm giảm hiệu năng mô hình. Nếu loại bỏ thì phải huấn luyện lại và so sánh để xác nhận không giảm hiệu năng được đánh giá không đáng với lợi ích thu được (giảm 2/16 chiều dữ liệu, không đáng kể về mặt tính toán).

## 5. So sánh Random Forest và SVM

| Tiêu chí              | Random Forest | SVM       | Mô hình tốt hơn               |
|-----------------------|---------------|-----------|-------------------------------|
| F1 cross-validation   | 0,9972        | 0,9950    | Random Forest                 |
| F1 trên test          | 0,9958        | 0,9938    | Random Forest                 |
| Recall trên test      | 0,9938        | 0,9903    | Random Forest                 |
| False Negative (test) | 14            | 22        | Random Forest                 |
| Thời gian CV (5-fold) | 8,2 giây      | 39,8 giây | Random Forest (~5x nhanh hơn) |
| Thời gian fit cuối    | 1,5 giây      | 12,3 giây | Random Forest (~8x nhanh hơn) |

Random Forest vượt trội hơn SVM ở mọi tiêu chí đã đo trong tuần này — hiệu năng cao hơn nhẹ và tốc độ nhanh hơn đáng kể. Đặc biệt đáng chú ý ở khía cạnh bảo mật: Random Forest bỏ sót ít câu tấn công thật hơn (FN=14 so với FN=22), là yếu tố quan trọng hơn Precision đối với một hệ thống phát hiện xâm nhập. Kết quả này sẽ được đối chiếu lại ở Tuần 7 cùng với Tầng 2 và Tầng 3 để có kết luận so sánh toàn diện giữa học máy cổ điển và học sâu.

## 6. Rủi ro kỹ thuật khi bước sang Tuần 5 (Thi công Tầng 2)

Nhầm lẫn dữ liệu: Dễ gọi nhầm file toàn bộ `train.csv` (dùng cho Tầng 1) thay vì cặp phân chia `train_split / val_split` (tỷ lệ 80/20) đang nằm cùng thư mục `datasets/processed/`.

Sai lệch logic tiền xử lý: Tự cài đặt cơ chế Head-Tail truncation (125 ký tự đầu + 125 ký tự cuối cho chuỗi  $>250$ ) dễ dính lỗi lệch chỉ số (off-by-one); bắt buộc phải tái sử dụng nguyên trạng `artifacts/vocab.json` (96 token) và `artifacts/max_len.json` từ Tuần 3 thay vì tính lại từ đầu.

Sai lệch chuẩn kiến trúc (Baseline Drift): Mọi thay đổi về cấu trúc mạng (`Embedding(96, 64) → LSTM(64) → Dropout(0.2) → Dense(1, sigmoid)`) hoặc siêu tham số (batch size 64, Adam lr=0.001, patience=5, tối đa 30 epoch) sẽ làm mất tính công bằng khi đối chiếu thực nghiệm với Tầng 3 (LSTM + Attention) ở Tuần 6–7.

Áp lực thời gian huấn luyện: Mạng LSTM lặp qua nhiều epoch tốn tài nguyên và thời gian hơn đáng kể so với RF/SVM; cần chạy thử 2–3 epoch đầu để ước lượng tốc độ thực tế, tránh bị động tiến độ.

Mất tín hiệu payload ở nhóm câu dài: Nhóm truy vấn  $>250$  ký tự chiếm 4.4% dữ liệu nhưng có tỷ lệ SQLi lên tới 96.7%; việc cắt bỏ đoạn giữa thân câu tiềm ẩn nguy cơ triệt tiêu dấu vết tấn công, bắt buộc phải theo dõi và đánh giá hiệu năng riêng trên nhóm này thay vì chỉ nhìn vào chỉ số tổng thể.

