

BÁO CÁO TIẾN ĐỘ — TUẦN 5

Thi công Tầng 2: Mô hình LSTM Baseline

Sinh viên thực hiện:	Nguyễn Tấn Đăng Khương
Giai đoạn:	Tuần 5 / 10 — Thi công

1. Mục tiêu Tuần 5

Tuần 5 thực hiện thi công Tầng 2 của hệ thống - mô hình LSTM baseline, học trực tiếp từ chuỗi ký tự của câu truy vấn SQL, không dùng đặc trưng thủ công như Tầng 1. Các mục tiêu cụ thể:

- Cài đặt hàm chuyển câu truy vấn thành sequence số nguyên theo đúng đặc tả Pipeline 2 đã chốt ở Tuần 3 (vocab 96 token, max_len=250, head+tail truncation, post-padding).
- Xây dựng và huấn luyện mô hình LSTM baseline theo đúng kiến trúc đã chốt.
- Ra quyết định về việc áp dụng class_weight để xử lý mất cân bằng lớp (63/37).
- Đánh giá trên cùng test.csv đã dùng cho Tầng 1, đảm bảo so sánh công bằng.
- Lưu model, artifact phục vụ tái lập ở Tầng 3 (Tuần 6).

2. Cài đặt hàm chuyển đổi Query → Sequence (Ngày 1)

2.1. Đặc tả tái sử dụng từ Tuần 3

Hàm query_to_sequence() tái sử dụng nguyên trạng hai artifact đã tạo ở Tuần 3, không tính toán lại:

- artifacts/vocab.json — 96 token (94 ký tự thật có tần suất ≥ 10 trong train + $\langle \text{PAD} \rangle = 0$ + $\langle \text{UNK} \rangle = 1$).
- artifacts/max_len.json — max_len=250, chiến lược truncating head+tail (125 ký tự đầu + 125 ký tự cuối), padding kiểu post.

2.2. Kết quả kiểm thử

Ba test case được thiết kế để kiểm tra ba nhánh logic riêng biệt của hàm.

Test case	Nội dung kiểm tra	Kết quả
1. Câu ngắn	"SELECT * FROM users" (19 ký tự) — kiểm tra post-padding	Đạt — 231 vị trí PAD, đúng bằng 250-19
2. Câu dài (bản sửa)	150×'A' + chuỗi giữa×10 + 150×'Z' (550 ký tự) — kiểm tra head+tail truncation không lệch off-by-one	Đạt tuyệt đối — 125 vị trí đầu = 'A', 125 vị trí cuối = 'Z', vị trí nối (124/125) chính xác
3. Ký tự lạ	"SELECT 트림 FROM test" — ký tự ngoài vocab phải map sang $\langle \text{UNK} \rangle$	Đạt — 2 lần xuất hiện $\langle \text{UNK} \rangle$, đúng bằng số ký tự lạ

2.3. Kết quả áp dụng lên toàn bộ dữ liệu

Sau khi cả 3 test case đạt yêu cầu, hàm được áp dụng lên toàn bộ ba tập dữ liệu, thu được ba ma trận sequence có shape khớp chính xác với số dòng đã ghi nhận từ Tuần 2-3:

- train_split_sequences.npy — (19.779, 250)


- val_split_sequences.npy — (4.945, 250)
- test_sequences.npy — (6.181, 250)

3. Kiến trúc mô hình LSTM Baseline (Ngày 2)

Kiến trúc cài đặt đúng theo đặc tả đã chốt ở Tuần 3, không thay đổi:

- Embedding(input_dim=96, output_dim=64)
- LSTM(units=64, return_sequences=False)
- Dropout(0.2)
- Dense(1, activation='sigmoid')
- Loss: binary_crossentropy — Optimizer: Adam(learning_rate=0.001)

Lưu ý kỹ thuật: phiên bản Keras 3 (TensorFlow 2.16+) không tự build Sequential model chỉ từ khai báo lớp — cần thêm lớp Input(shape=(250,)) tường minh để model.summary() hiển thị đầy đủ Output Shape và Param#, thay vì trạng thái "unbuilt".



VOCAB_SIZE: 96

Model: "sequential_1"

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, 250, 64)	6,144
lstm_1 (LSTM)	(None, 64)	33,024
dropout_1 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65

Total params: 39,233 (153.25 KB)

Trainable params: 39,233 (153.25 KB)

Non-trainable params: 0 (0.00 B)

Hình 1. model.summary() của mô hình LSTM baseline sau khi build

Kiểm chứng số lượng tham số bằng công thức, đối chiếu khớp với model.summary():

Lớp	Công thức	Số tham số
Embedding	96×64	6.144
LSTM	$4 \times [(64+64) \times 64 + 64]$	33.024
Dropout	—	0
Dense	$64 \times 1 + 1$	65
Tổng cộng		39.233

4. Quá trình huấn luyện (Ngày 3–4)

4.1. Thử nghiệm ngắn 3 epoch (Ngày 3)

Mục tiêu: ước lượng thời gian huấn luyện thực tế và quan sát sơ bộ xu hướng loss/Precision/Recall trước khi cam kết huấn luyện đầy đủ. Thời gian chạy 3 epoch: 184,1 giây (~3,07 phút) → ước tính ~30,7 phút cho 30 epoch, khả thi trên máy hiện tại.

Kết quả 3 epoch thử nghiệm (chưa áp dụng class_weight):

Epoch	loss	val_loss	precision	recall	val_precision	val_recall
1	0,6211	0,6129	0,9305	0,1214	0,9739	0,1231
2	0,4896	0,2324	0,8070	0,4572	0,8355	0,9709
3	0,5436	0,6177	0,9504	0,2711	0,9910	0,1214

Nhận xét: val_loss giảm mạnh ở epoch 2 (0,2324) rồi thoái lui gần như hoàn toàn ở epoch 3 (0,6177) — dao động lớn giữa các epoch, đúng loại rủi ro đã lường trước trong kế hoạch Tuần 5 ("val_loss tăng ngay từ epoch 2–3 có thể là dấu hiệu learning rate chưa phù hợp"). Đồng thời, Precision luôn cao và ổn định (0,81–0,99) trong khi Recall thấp và dao động mạnh (0,12–0,97) — tín hiệu điển hình của mất cân bằng lớp ảnh hưởng đến khả năng nhận diện lớp thiểu số (SQLi).


4.2. Quyết định đã chốt

- Áp dụng class_weight='balanced' khi huấn luyện chính thức, tính bằng `sklearn.utils.class_weight.compute_class_weight` — cùng phương pháp đã dùng cho Random Forest/SVM ở Tuần 4. Giá trị: lớp 0 (hợp lệ) = 0,7913 — lớp 1 (SQLi) = 1,3581.
- Không điều chỉnh learning_rate mặc dù quan sát thấy dao động ở Ngày 3, vì đây là tham số đã chốt ở Tuần 3 cần giữ nguyên cho Tăng 3 (Tuần 6) để so sánh công bằng ở Tuần 7. Quyết định: tiến hành huấn luyện chính thức ngay, tin tưởng cơ chế EarlyStopping(patience=5, restore_best_weights=True) sẽ tự chọn epoch có val_loss tốt nhất bất kể dao động giữa chừng.

4.3. Huấn luyện chính thức (Ngày 4)

Cấu hình: epochs tối đa = 30, batch_size = 64, class_weight áp dụng như trên, EarlyStopping theo dõi val_loss với patience = 5, restore_best_weights = True.

Số epoch thực tế đã chạy	27 (dừng bởi EarlyStopping = epoch tốt nhất 22 + patience 5)
Epoch có val_loss tốt nhất	22 — val_loss = 0,0141
Precision / Recall (train, epoch 22)	0,9990 / 0,9971
Precision / Recall (validation, epoch 22)	0,9983 / 0,9956
Thời gian huấn luyện tổng	28,50 phút



Hình 2. Loss/val_loss và Precision/Recall qua từng epoch (đường đứt nét: epoch tốt nhất = 22)

Đối chiếu với thử nghiệm 3 epoch ở Ngày 3: dao động thoái lui đã quan sát trước đó không lặp lại nghiêm trọng khi huấn luyện đầy đủ. Sau bước nhảy hội tụ ở epoch 3 (loss giảm từ 0,66 xuống 0,23), mô hình ổn định dần và chỉ còn nhiễu nhỏ (epoch 8–9, 14, 16), không thoái lui mạnh như đã thấy ở thử nghiệm ngắn. Kết luận: dao động ở Ngày 3 là nhiễu giai đoạn đầu huấn luyện khi trọng số còn gần điểm khởi tạo ngẫu nhiên, không phải vấn đề cấu trúc của mô hình hay learning rate.

5. Kết quả đánh giá trên test.csv (Ngày 5)

Đánh giá thực hiện trên model tại epoch 22 (trọng số tốt nhất, được giữ lại tự động nhờ `restore_best_weights=True`), trên đúng tập test.csv (6.181 dòng) đã dùng cho Tầng 1 ở Tuần 4 — đảm bảo so sánh công bằng, không chia lại dữ liệu.

Precision	0,9987
Recall	0,9930
F1-score	0,9958 (chính xác: 0,995814)
Confusion Matrix	TN=3902, FP=3, FN=16, TP=2260

5.1. Bảng so sánh với Tầng 1 (Tuần 4)

Đối chiếu tổng số mẫu qua cả 3 mô hình (TN+FP=3.905, FN+TP=2.276) khớp tuyệt đối ở cả ba hàng — xác nhận cả ba mô hình đánh giá trên đúng cùng một tập test.csv, không có sai lệch dữ liệu.

Mô hình	Precision	Recall	F1-score	TN	FP	FN	TP
Random Forest	0,9978	0,9938	0,9958	3900	5	14	2262
SVM	0,9973	0,9903	0,9938	3899	6	22	2254
LSTM baseline	0,9987	0,9930	0,9958	3902	3	16	2260

5.2. Nhận định ban đầu

F1-score của Random Forest (0,995818) và LSTM baseline (0,995814) gần như trùng khớp tuyệt đối - chênh lệch chỉ 0,000004, không có ý nghĩa để kết luận mô hình nào vượt trội hơn. SVM thấp hơn rõ rệt hơn cả hai (F1 = 0,993826). Đây là kết quả trùng khớp với rủi ro đã được ghi nhận trước trong kế hoạch Tuần 5: khả năng LSTM không vượt trội hơn Tầng 1 do 16 đặc trưng thủ công đã nắm bắt tốt tín hiệu phân biệt, khiến deep learning không còn nhiều dư địa cải thiện thêm trên dataset cụ thể này. Đây là phát hiện thực nghiệm hợp lệ, không phải lỗi kỹ thuật, cần phân tích nguyên nhân sâu hơn ở Tuần 7 khi có đủ dữ liệu từ cả ba tầng.

Một khác biệt đáng chú ý: LSTM có Precision cao hơn (FP=3 so với FP=5 của RF — ít gần cờ sai truy vấn hợp lệ hơn), nhưng Recall thấp hơn một chút (FN=16 so với FN=14 của RF — bỏ sót nhiều truy vấn SQLi hơn). Trong bài toán bảo mật, bỏ sót tấn công thật (FN) thường được xem là rủi ro nghiêm trọng hơn báo động nhầm (FP) — điểm này cần được thảo luận kỹ hơn khi có đủ dữ liệu ba tầng ở Tuần 7, chưa vội kết luận ở giai đoạn này.